1. kafka:

- 1.消息分类按不同类别,分成不同的Topic,Topic又拆分成多个partition,每个partition均衡分散到不同的服务器(提高并发访问的能力)
- 2.消费者按顺序从partition中读取,不支持随机读取数据,但可通过改变保存到zookeeper中的offset位置实现从任意位置开始读取
 - 3. 服务器消息定时清除(不管有没有消费)
- 4.每个partition还可以设置备份到其他服务器上的个数以保证数据的可用性。通过Leader,Follower方式
- 5.zookeeper保存kafka服务器和客户端的所有状态信息.(确保实际的客户端和服务器轻量级)
- 6.在kafka中,一个partition中的消息只会被group中的一个consumer消费;每个group中consumer消息消费互相独立;我们可以认为一个group是一个"订阅"者,一个Topic中的每个partions,只会被一个"订阅者"中的一个consumer消费,不过一个consumer可以消费多个partitions中的消息
- 7.如果所有的consumer都具有相同的group,这种情况和queue模式很像; 消息将会在consumers之间负载均衡.
- 8.如果所有的consumer都具有不同的group,那这就是"发布-订阅";消息将会广播给所有的消费者.
- 9.持久性,当收到的消息时先buffer起来,等到了一定的阀值再写入磁盘文件,减少磁盘IO.在一定程度上依赖OS的文件系统(对文件系统本身优化几乎不可能)
- 10.除了磁盘工〇,还应考虑网络工〇,批量对消息发送和接收,并对消息进行压缩。
- 11.在JMS实现中,Topic模型基于push方式,即broker将消息推送给consumer端.不过在kafka中,采用了pull方式,即consumer在和broker建立连接之后,主动去pull(或者说fetch)消息;这种模式有些优点,首先consumer端可以根据自己的消费能力适时的去fetch消息并处理,且可以控制消息消费的进度(offset);此外,消费者可以良好的控制消息消费的数量,batch fetch.
- 12.kafka无需记录消息是否接收成功,是否要重新发送等,所以kafka的 producer是非常轻量级的,consumer端也只需要将fetch后的offset位置注册到zookeeper,所以也是非常轻量级的.

--kafka使用场景

对于一些常规的消息系统,kafka是个不错的选

择;partitons/replication和容错,可以使kafka具有良好的扩展性和性能优势.

不过到目前为止,我们应该很清楚认识到,kafka并没有提供JMS中的"事务

性""消息传输担保(消息确认机制)""消息分组"等企业级特性;

kafka只能使用作为"常规"的消息系统,在一定程度上,尚未确保消息的发送与接收绝对可靠(比如,消息重发,消息发送丢失等)

kafka的特性决定它非常适合作为"日志收集中心";application可以将操作日志"批量""异步"的发送到kafka集群中,

而不是保存在本地或者DB中; kafka可以批量提交消息/压缩消息等,这对producer端而言,几乎感觉不到性能的开支.

consumer端采用批量fetch方式,此时consumer端也可以使hadoop等其他系统化的存储和分析系统

2. kafka和RabbitMO区别:

- 1、RabbitMQ,遵循AMQP协议,由内在高并发的erlanng语言开发,用在实时的对可靠性要求比较高的消息传递上(有消息确认机制)。
- 2、kafka是Linkedin于2010年12月份开源的<u>消息发布订阅系统,它主要用于处理活跃的流式数据,大数据量的数据处理上(无消息确认机制,但吞吐量高)</u>,kafka用zk做集群负载均衡。
- 3. 项目中哪里用到了kafka, 它有什么特性?
 - a. 场景:
 - i. 大数据部门流数据处理;
 - ii. elk;
 - b. 特性:
 - i. 它被设计为一个分布式系统, 易于向外扩展;
 - ii. 它同时为发布和订阅提供高吞叶量;
 - iii. 它支持多订阅者,当失败时能自动平衡消费者;
 - iv. 它将消息持久化到磁盘,因此可用于批量消费,例如ETL,以及实时应用程序。
- **4.** kafka数据分区和消费者的关系,kafka的数据offset读取流程,kafka内部如何保证顺序,结合外部组件如何保证消费者的顺序?
 - 1、kafka数据分区和消费者的关系: 1个partition只能被同组的一个consumer消费,同组的consumer则起到均衡效果
 - 2、kafka的数据offset读取流程
 - 1.连接ZK集群,从ZK中拿到对应topic的partition信息和partition的Leader的相关信息
 - 2.连接到对应Leader对应的broker
 - 3.consumer将自己保存的offset发送给Leader
 - 4.Leader根据offset等信息定位到segment(索引文件和日志文

件)

5.根据索引文件中的内容,定位到日志文件中该偏移量对应的开始 位置读取相应长度的数据并返回给consumer

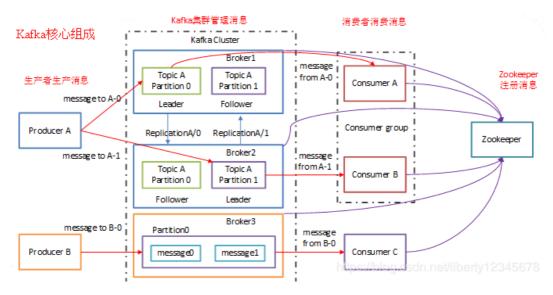
3、kafka内部如何保证顺序:

kafka只能保证partition内是有序的,但是partition间的有序是没办法的。爱奇艺的搜索架构,是从业务上把需要有序的打到同一个partition。

4、

5. kafka工作流程?

Apache Kafka是分布式发布-订阅消息系统。它最初由LinkedIn公司开发,之后成为Apache项目的一部分。Kafka是一种快速、可扩展的、设计内在就是分布式的,分区的和可复制的提交日志服务。



- a. 生产者定期向主题发送消息。
- b. Kafka代理存储为该特定主题配置的分区中的所有消息。 它确保消息 在分区之间平等共享。 如果生产者发送两个消息并且有两个分区, Kafka将在第一分区中存储一个消息,在第二分区中存储第二消息。
- c. 消费者订阅特定主题。
- d. 一旦消费者订阅主题,Kafka将向消费者提供主题的当前偏移,并且还将偏移保存在Zookeeper系综中。
- e. 消费者将定期请求Kafka(如100 Ms)新消息。
- f. 一旦Kafka收到来自生产者的消息、它将这些消息转发给消费者。
- a. 消费者将收到消息并进行处理。
- h. 一旦消息被处理,消费者将向Kafka代理发送确认。

- i. 一旦Kafka收到确认,它将偏移更改为新值,并在Zookeeper中更新它。由于偏移在Zookeeper中维护,消费者可以正确地读取下一封邮件,即使在服务器暴力期间。
- j. 以上流程将重复, 直到消费者停止请求。
- k. 消费者可以随时回退/跳到所需的主题偏移量,并阅读所有后续消息。

6.